



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE MATEMÁTICAS
DEPARTAMENTO DE ESTADÍSTICA
PRIMER SEMESTRE 2026

Proyecto NHANES

Cholesterol vs Edad

EYP230I/2307 - Análisis de Regresión

Profesor: Eloy Alvarado **Ayudante:** Matías A. Pineda

Grupo 1

Integrantes:
Vicente Alfaro, Cristian Chávez, Isidora Guíñez, Bruno Parra

Fecha de entrega: 27 de mayo de 2026



Índice de contenido

1. Pregunta de Investigación y Motivación	2
1.1. Pregunta de Investigación	2
2. Fuente de Datos y Consideraciones Éticas	2
2.1. Origen de los Datos y Unidad de Observación	2
2.2. Consideraciones Éticas	2
3. EDA	2
3.1. Tratamiento de los NaN	2
3.2. Codificación	2
3.3. Descripción de Variables	2
4. Plan de Modelamiento Estadístico	3

Índice de Tablas

Índice de figuras



1. Pregunta de Investigación y Motivación

1.1. Pregunta de Investigación

¿Es la relación entre la edad y el colesterol total estrictamente lineal, o existe una caída/estabilización en edades muy avanzadas, ajustando por presión arterial sistólica y peso?

2. Fuente de Datos y Consideraciones Éticas

2.1. Origen de los Datos y Unidad de Observación

Los datos utilizados en este estudio provienen de la *National Health and Nutrition Examination Survey* (NHANES), un programa de estudios diseñado para evaluar el estado de salud y nutrición de adultos y niños en los Estados Unidos. Específicamente, se utiliza el ciclo de datos continuos correspondiente al período 2021-2023. La unidad de observación es una persona individual examinada [?].

La base de datos original se distribuye en múltiples módulos independientes en formato SAS Transport (.xpt). Para la consolidación de la muestra analítica, se cruzaron los registros de cuatro módulos clave utilizando el identificador único de cada paciente (SEQN): Demografía (DEMO_L), Medidas Corporales (BMX_L), Presión Arterial (BPXO_L) y Colesterol Total (TCHOL_L).

2.2. Consideraciones Éticas

El uso de esta base de datos se enmarca en un contexto estrictamente académico y estadístico. Los datos de NHANES son de dominio público y han sido previamente anonimizados por el *National Center for Health Statistics* (NCHS) del CDC, garantizando que no sea posible identificar a los individuos encuestados. El análisis propuesto no busca la estigmatización de ningún subgrupo demográfico, sino comprender las relaciones entre indicadores antropométricos y cardiovasculares.

3. EDA

3.1. Tratamiento de los NaN

3.2. Codificación

3.3. Descripción de Variables

Variable dependiente: Colesterol Total (LBXTC)

Variables independientes:



- **Edad** (RIDAGEYR): Variable numérica que indica la edad del participante en años en el momento del examen.
- **Sexo** (RIAGENDR): Variable categórica codificada (1 = Masculino, 2 = Femenino).
- **Índice de Masa Corporal** (BMXBMI): Variable numérica continua (kg/m^2) calculada a partir del peso y la altura al momento de la medición.
- **Presión Arterial Sistólica** (BPXOSY1): Variable numérica continua (mm Hg) correspondiente a la primera medición de la presión sistólica (fase de contracción del corazón).
- **Presión Arterial Diastólica** (BPXODI1): Variable numérica continua (mm Hg) correspondiente a la primera medición de la presión diastólica (fase de relajación del corazón).

4. Plan de Modelamiento Estadístico



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE MATEMÁTICAS
DEPARTAMENTO DE ESTADÍSTICA

5. Referencias bibliográficas

National Center for Health Statistics. (2024, diciembre). *NHANES*. Centers for Disease Control and Prevention. <https://www.cdc.gov/nchs/nhanes/>