



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE MATEMÁTICAS
DEPARTAMENTO DE ESTADÍSTICA
PRIMER SEMESTRE 2026

Proyecto NHANES

Cholesterol vs Edad

EYP230I/2307 - Análisis de Regresión

Profesor: Eloy Alvarado **Ayudante:** Matías A. Pineda

Grupo 1

Integrantes:
Vicente Alfaro, Cristian Chávez, Isidora Guíñez, Bruno Parra

Fecha de entrega: 27 de mayo de 2026



Índice de contenido

1. Pregunta de Investigación y Motivación	2
1.1. Pregunta de Investigación	2
2. Fuente de Datos y Consideraciones Éticas	2
2.1. Origen de los Datos y Unidad de Observación	2
2.2. Consideraciones Éticas	2
3. EDA	2
3.1. Tratamiento de los NaN	2
3.2. Descripción de Variables	3
4. Plan de Modelamiento Estadístico	5
5. Referencias bibliográficas	7

Índice de Tablas

1. Valores Faltantes por Variable	3
2. Matriz de Correlaciones	4

Índice de figuras

1. Distribución del colesterol Total	4
2. Colesterol Total vs Edad	4
3. Colestero Total vs Edad por Sexo	5



1. Pregunta de Investigación y Motivación

1.1. Pregunta de Investigación

¿Es la relación entre la edad y el colesterol total estrictamente lineal, o existe una caída/estabilización en edades muy avanzadas, ajustando por presión arterial sistólica y peso?

2. Fuente de Datos y Consideraciones Éticas

2.1. Origen de los Datos y Unidad de Observación

Los datos utilizados en este estudio provienen de la *National Health and Nutrition Examination Survey* (NHANES), un programa de estudios diseñado para evaluar el estado de salud y nutrición de adultos y niños en los Estados Unidos. Específicamente, se utiliza el ciclo de datos continuos correspondiente al período 2021-2023. La unidad de observación es una persona individual examinada (NCHS, 2024).

La base de datos original se distribuye en múltiples módulos independientes en formato SAS Transport (.xpt). Para la consolidación de la muestra analítica, se cruzaron los registros de cuatro módulos clave utilizando el identificador único de cada paciente (SEQN): Demografía (DEMO_L), Medidas Corporales (BMX_L), Presión Arterial (BPXO_L) y Colesterol Total (TCHOL_L).

2.2. Consideraciones Éticas

El uso de esta base de datos se enmarca en un contexto estrictamente académico y estadístico. Los datos de NHANES son de dominio público y han sido previamente anonimizados por el *National Center for Health Statistics* (NCHS) del CDC, garantizando que no sea posible identificar a los individuos encuestados. El análisis propuesto no busca la estigmatización de ningún subgrupo demográfico, sino comprender las relaciones entre indicadores antropométricos y cardiovasculares.

3. EDA

3.1. Tratamiento de los NaN

Para el tratamiento de los valores faltantes, en primer lugar se analizó la proporción de datos faltantes por variable. Se identificó que las variables con mayor proporción de valores faltantes son `Colesterol` y `NSE_PIR`, con un 9.78% y 13.11% de datos faltantes respectivamente. Otras variables como `IMC`, `Presion_sis` y `Presion_dia` presentan un porcentaje de valores faltantes menor, alrededor del 1.61% y 3.74%.



Tabla 1

Valores Faltantes por Variable

Variable	Total_NA	Porcentaje_NA (%)
SEQN	0	0.00
Colesterol	620	9.78
Edad	0	0.00
Sexo	0	0.00
NSE_PIR	831	13.11
IMC	102	1.61
Presion_sis	214	3.74
Presion_dia	214	3.74

3.2. Descripción de Variables

■ Variable dependiente

- **Colesterol Total (LBXTC):** Variable numérica continua (mg/dL) que representa la concentración de colesterol total en sangre. El colesterol es un indicador clave de la salud cardiovascular,

■ Variable de interés

- **Edad (RIDAGEYR):** Variable numérica que indica la edad del participante en años en el momento del examen. Estudios muestran que existe una relación no lineal entre edad y colesterol total, con un aumento progresivo que se estabiliza e inclusive disminuye en edades avanzadas (Ferrara, et al. 1997)

■ Variables de control

- **Sexo (RIAGENDR):** Variable categórica codificada (0 = Masculino, 1 = Femenino). Es importante controlar por sexo debido a diferencias biológicas en el metabolismo de grasas (Blaak E. 2001).
- **Índice de Masa Corporal (BMXBMI):** Variable numérica continua (kg/m^2) calculada a partir del peso y la altura al momento de la medición. Es una métrica que mide el estado metabólico general, una persona mayor y muy delgada no tendrá el mismo colesterol que una persona mayor con obesidad.
- **Presión Arterial Sistólica (BPX0SY1):** Variable numérica continua (mm Hg) correspondiente a la primera medición de la presión sistólica (fase de contracción del corazón). La literatura sugiere que la presión sistólica y el colesterol están positivamente relacionados (Chen, et al. 2021).
- **Presión Arterial Diastólica (BPX0DI1):** Variable numérica continua (mm Hg) correspondiente a la primera medición de la presión diastólica (fase de relajación del corazón). Se agrega la presión diastólica para controlar la salud cardiovascular general.


ANÁLISIS DE CORRELACIONES:



Tabla 2
Matriz de Correlaciones


	Sexo	IMC	NSE	P. Sistólica	P. Diastólica	Edad	Edad ²
Sexo	1.0000	0.0622	-0.0756	-0.1325	-0.0530	-0.0158	-0.0215
IMC	0.0622	1.0000	-0.0555	0.0378	0.2167	0.0351	0.0117
NSE	-0.0756	-0.0555	1.0000	-0.0258	-0.0063	0.0823	0.0657
P. Sistólica	-0.1325	0.0378	-0.0258	1.0000	0.6196	0.3836	0.3825
P. Diastólica	-0.0530	0.2167	-0.0063	0.6196	1.0000	0.0239	-0.0220
Edad	-0.0158	0.0351	0.0823	0.3836	0.0239	1.0000	0.9866
Edad ²	-0.0215	0.0117	0.0657	0.3825	-0.0220	0.9866	1.0000

Imagen 1
Distribución del colesterol Total



ANÁLISIS DE LA DISTRIBUCION DEL COLESTEROL

Imagen 2
Colesterol Total vs Edad






ANÁLISIS DE LA RELACION ENTRE EDAD Y COLESTEROL

Imagen 3

Colestero Total vs Edad por Sexo



ANÁLISIS DE LA RELACION ENTRE EDAD Y COLESTEROL POR SEXO

4. Plan de Modelamiento Estadístico

Como ya se mencionó en la sección anterior, la observación principal en los gráficos es que la dependencia del colesterol a la edad es de forma cuadrática. Como esta relación no necesariamente está centrada en el cero, tampoco lo estará la hipotética parábola, consecuentemente, la relación estará dada necesariamente por dos covariables: edad y edad². Como el objetivo es comparar con una relación estrictamente lineal, la pregunta de investigación se reduce a medir la importancia de la covariable edad². Considerando esto, se proponen dos modelos anidados con intercepto con las siguientes covariables: $X_1 = \text{RIAGENDIR} - 1$, sexo codificado en 0 para hombres y 1 para mujeres; $X_2 = \text{BMXBMI}$, índice de masa corporal; $X_3 = \text{INDFMPIR}$, razón de ingresos familiares respecto al umbral de pobreza, para medir el nivel socioeconómico del sujeto de la observación; $X_4 = \frac{\text{BPXOSY1} + \text{BPXOSY2} + \text{BPXOSY3}}{3}$, promedio simple de las tres mediciones de la presión sistólica; $X_5 = \frac{\text{BPXODI1} + \text{BPXODI2} + \text{BPXODI3}}{3}$, promedio simple de las tres mediciones de la presión diastólica; $X_6 = \text{RIDAGEYR}$, edad; $X_7 = \text{RIDAGEYR}^2$, edad al cuadrado. Estas covariables nos definen los siguientes modelos:

- Modelo completo Ω

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \beta_7 X_7 + \varepsilon$$

- Modelo reducido ω

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \varepsilon$$



Donde Y es la variable dependiente, en este caso, el colesterol. Con respecto al error ε asumiremos $\mathbb{E}[\varepsilon|X] = 0$ exogeneidad media para que los estimadores por mínimos cuadrados sean insesgados, por otro lado, debido a que las observaciones son de personas independientes, es seguro asumir $\text{Cov}(\varepsilon|X) = \sigma^2 I_n$ homocedasticidad y no correlación condicional.

Teniendo claramente establecido el modelo, a continuación se comentarán los diagnósticos previstos: en primera instancia se realizarán gráficos para conocer los datos y cómo resultó el ajuste. De los gráficos mencionados los primeros análisis serán las proyecciones de los errores versus cada variable independiente, buscando detectar relaciones no lineales, heterocedasticidad o alguna combinación de estas. Además de los gráficos anteriores se realizará un qqplot

Anteriormente se mencionó que no se integraron las variables que visualmente tenían relaciones directamente lineales para evitar problemas de colinealidad que empeoren el condicionamiento de la matriz de covariables. Para formalizar este análisis con las variables que sí se integraron al modelo se revisará el condicionamiento de la matriz y los VIF por variable.

Los test más importante en cuanto a evaluar directamente nuestra pregunta de investigación es comparar modelos anidados incluyendo o no el coeficiente que acompaña al término de edad² (comparación de los modelos Ω y ω descritos anteriormente); además para ambos por separado se va a testear la posibilidad de reducir otras variables bajo criterio de eliminación, revisando valores de CP de Mallows y R_a^2 .



5. Referencias bibliográficas

- National Center for Health Statistics. (2024, diciembre). *NHANES*. Centers for Disease Control and Prevention. <https://www.cdc.gov/nchs/nhanes/>
- Ferrara, A., Barrett-Connor, E., & Shan, J. (1997). Total, LDL, and HDL cholesterol decrease with age in older men and women. The Rancho Bernardo Study 1984-1994. *Circulation*, 96(1), 37–43. <https://doi.org/10.1161/01.cir.96.1.37>
- Blaak E. (2001). Gender differences in fat metabolism. *Current opinion in clinical nutrition and metabolic care*, 4(6), 499–502. <https://doi.org/10.1097/00075197-200111000-00006>
- Chen, H., Chen, Y., Wu, W. et al. Total cholesterol, arterial stiffness, and systolic blood pressure: a mediation analysis. *Sci Rep* 11, 1330 (2021). <https://doi.org/10.1038/s41598-020-79368-x>