



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE MATEMÁTICAS
DEPARTAMENTO DE ESTADÍSTICA
PRIMER SEMESTRE 2026

Proyecto NHANES

¿Es el colesterol lineal a lo largo de los años?

EYP230I/2307 - Análisis de Regresión

Profesor: Eloy Alvarado **Ayudante:** Matías A. Pineda

Grupo 1

Integrantes:

Vicente Alfaro, Cristian Chávez, Isidora Guíñez, Bruno Parra

Fecha de entrega: 27 de mayo de 2026



Índice de contenido

1. Introducción	2
1.1. Pregunta de Investigación	2
2. Datos y Variables de Estudio	2
2.1. Origen de los Datos y Unidad de Observación	2
2.2. Consideraciones Éticas	2
2.3. Descripción de Variables	2
3. EDA	3
3.1. Tratamiento de los NaN	4
3.2. Codificaciones	4
3.3. Exploración Visual	5
4. Plan de Modelamiento Estadístico	6
5. Próximos Pasos y Reproducibilidad	7

Índice de Tablas

1. Valores Faltantes por Variable	4
2. Matriz de Correlaciones	6

Índice de figuras

1. Distribución del colesterol Total	5
2. Colesterol Total vs Edad	5
3. Colesterol Total vs Edad por Sexo	6



1. Introducción

La cantidad de colesterol en sangre es un indicador relevante para evaluar la salud cardiovascular de las personas, por ejemplo, niveles altos podrían estar directamente relacionados con enfermedades al sistema circulatorio y/o riesgos metabólicos. Sin embargo, su comportamiento a través de la vida no necesariamente sigue un patrón constante, es más, ni siquiera lineal. El presente trabajo busca estudiar la relación entre edad y colesterol. En particular, se analiza si los niveles de colesterol en sangre aumentan de forma constante o, por el contrario, en edades más avanzadas presenta cierta clase de estabilización o decaimiento. El objetivo final es construir un modelo estadístico con el cual se pueda evaluar a través de datos la relación mencionada.

1.1. Pregunta de Investigación

¿Es la relación entre la edad y el colesterol total estrictamente lineal, o existe una caída/estabilización en edades avanzadas, ajustando por sexo, IMC, nivel socioeconómico y presión arterial sistólica y diastólica?

2. Datos y Variables de Estudio

2.1. Origen de los Datos y Unidad de Observación

Los datos utilizados en este estudio provienen de la *National Health and Nutrition Examination Survey* (NHANES), un programa de estudios diseñado para evaluar el estado de salud y nutrición de adultos y niños en los Estados Unidos. En particular, se utiliza el ciclo de datos del período 2021-2023. La unidad de observación corresponde a un individuo examinado dentro de la encuesta ([National Center for Health Statistics, 2024](#)). La base de datos original se distribuye en múltiples módulos independientes en formato SAS Transport (.xpt). Para la consolidación de la muestra analítica, se cruzaron los registros de cuatro módulos clave utilizando el identificador único de cada paciente (SEQN): Demografía (DEMO_L), Medidas Corporales (BMX_L), Presión Arterial (BPXO_L) y Colesterol Total (TCHOL_L). La base de datos cruda resultante consta de un total de $N = 6337$ y 8 variables de estudio.

2.2. Consideraciones Éticas

El uso de esta base de datos se enmarca en un contexto estrictamente académico y estadístico. Los datos de NHANES son de dominio público y han sido previamente anonimizados por el *National Center for Health Statistics* (NCHS) del CDC, garantizando que no sea posible identificar a los individuos encuestados. El análisis propuesto no busca la estigmatización de ningún subgrupo demográfico, sino comprender las relaciones entre las medidas externas del cuerpo e indicadores cardiovasculares.

2.3. Descripción de Variables

- Variable dependiente



- **Colesterol Total (LBXTC):** Variable numérica continua medida en (mg/dL) que representa la concentración de colesterol total en sangre. El colesterol es un indicador clave de la salud cardiovascular, ya que niveles elevados se asocian con un mayor riesgo de enfermedades cardiovasculares.
- **Variable de interés**
 - **Edad (RIDAGEYR):** Variable numérica que indica la edad del participante en años al momento de la realización del examen. Estudios muestran que existe una relación no lineal entre la edad y el colesterol total, caracterizada por un aumento progresivo durante la adultez que tiende a estabilizarse o incluso disminuir en edades avanzadas ([Ferrara et al., 1997](#)). Además para este trabajo se considero únicamente a participantes de 18 años o más.
- **Variables de control**
 - **Sexo (RIAGENDR):** Variable categórica codificada (0 = Masculino, 1 = Femenino). Se incorpora como variable de control debido a las diferencias biológicas y hormonales existentes en el metabolismo de las grasas entre hombres y mujeres ([Blaak, 2001](#)).
 - **Índice de Masa Corporal (BMXBMI):** Variable numérica continua medida en (kg/m^2), calculada a partir del peso y la altura del individuo. El IMC se utiliza como indicador del estado nutricional y metabólico, factores que pueden influir directamente en los niveles de colesterol de una persona.
 - **Presión Arterial Sistólica:** Variable numérica continua medida en mmHg, correspondiente a la media de las 3 mediciones disponibles (BPXOSY1, BPXOSY2, BPXOSY3) de la presión sistólica (fase de contracción del corazón). La literatura sugiere que la presión sistólica y el colesterol están positivamente relacionados ([Chen et al., 2021](#)).
 - **Presión Arterial Diastólica:** Variable numérica continua medida en mmHg, correspondiente a la media de las 3 mediciones disponibles (BPXODI1, BPXODI2, BPXODI3) de la presión diastólica (fase de relajación del corazón). Se agrega la presión diastólica para controlar la salud cardiovascular general.
 - **Nivel Socioeconómico:** Variable numérica continua que representa la razón entre el ingreso familiar y el umbral de la pobreza (Poverty-Income Ratio). Toma valores desde 0 (pobreza extrema) hasta 5.0 (ingresos altos). Se toma como variable de control dado que el nivel adquisitivo determina en gran medida la calidad de la dieta y el estilo de vida de la persona.

3. EDA

En esta sección se realiza un análisis exploratorio de los datos con el objetivo de comprender las principales características de las variables consideradas en el estudio, identificar patrones y detectar relaciones relevantes entre ellas. En particular, se analiza la presencia de valores faltantes, las codificaciones utiliza-



das y el comportamiento de las variables mediante gráficos y estadística. Este análisis permite evaluar la calidad de los datos y orientar la construcción del modelo de regresión.

3.1. Tratamiento de los NaN

Para el tratamiento de los valores faltantes, en primer lugar se analizó la proporción de datos faltantes por variable. Como se muestra en la Tabla 1, las variables con mayor proporción de valores faltantes corresponden a Colesterol y NSE_PIR, con un 9.78 % y 13.11 % de datos faltantes, respectivamente. Por otro lado, variables como IMC, Presion_sis y Presion_dia, presentan porcentajes menores de valores faltantes, alrededor de un 1.61 % y 3.74 %.

Considerando que los porcentajes de datos faltantes son relativamente bajos, se decidió eliminar aquellos registros que presentaran al menos un valor faltante en alguna de las variables analizadas.

Tabla 1

Valores Faltantes por Variable

Variable	Total_NA	Porcentaje_NA (%)
SEQN	0	0.00
Colesterol	620	9.78
Edad	0	0.00
Sexo	0	0.00
NSE_PIR	831	13.11
IMC	102	1.61
Presion_sis	214	3.74
Presion_dia	214	3.74

En la tabla 1 se muestra la cantidad de datos faltantes en cada variable, de manera absoluta y porcentual. Lo anterior se realizó únicamente para las variables elegidas para la regresión, resultando en un dataset de $N = 4784$ muestras ([National Center for Health Statistics, 2024](#)).


3.2. Codificaciones

Dentro del conjunto de variables consideradas en el análisis, únicamente la variable **Sexo** (RIAGENDR) requirió una codificación previa para su incorporación en el modelo estadístico. En particular, se utilizó una codificación binaria, asignando el valor 0 a los participantes de sexo masculino y el valor 1 a los participantes de sexo femenino.

3.3. Exploración Visual

Imagen 1


Distribución del colesterol Total



La imagen 1 muestra la distribución del colesterol total en la muestra analizada. Se observa una distribución unimodal, con una mayor concentración de observaciones entre los 150 y 220 mg/dl aproximadamente. El valor más frecuente se encuentra cercano a los 180 mg/dl ([National Center for Health Statistics, 2024](#)). Además, la distribución presenta una ligera asimetría positiva, evidenciando una cola más extensa hacia valores altos de colesterol. Esto nos indica la presencia de algunos individuos con niveles considerablemente elevados de colesterol, alcanzando valores superiores a 300 mg/dL. Sin embargo, estos casos son poco frecuentes en comparación con la concentración principal de los datos. En términos generales, la distribución del colesterol total parece relativamente cercana a una distribución normal, aunque presenta cierta desviación hacia la derecha debido a la presencia de valores elevados.

Imagen 2

Colesterol Total vs Edad




Al graficar las dos variables de interés (imagen 2), es posible apreciar que en cada edad los datos se concentran cerca de la media, es decir, al rededor de la linea roja. Viendo la dinámica de la curva de las medias, es posible notar como, a medida que avanza la edad, después de alcanzar un máximo en torno a los 50 años, el promedio baja. La curva general tiene una forma de monte lo cual asimilaría a una relación cuadrática entre ambos ([National Center for Health Statistics, 2024](#)).



Imagen 3

Colesterol Total vs Edad por Sexo



Al distinguir por sexo observamos como existe una diferencia en la tendencia de colesterol total. En hombres el colesterol alcanza su máximo alrededor de 45 años para luego ir a la baja, mientras que en mujeres se observa una curva más estable que alcanza su máximo en esperanza en los 60 años, por lo tanto, es prudente que el sexo sea una variable de control ([National Center for Health Statistics, 2024](#)).

Tabla 2

Matriz de Correlaciones

	Sexo	IMC	NSE	P. Sistólica	P. Diastólica	Edad	Edad ²
Sexo	1.0000	0.0622	-0.0756	-0.1325	-0.0530	-0.0158	-0.0215
IMC	0.0622	1.0000	-0.0555	0.0378	0.2167	0.0351	0.0117
NSE	-0.0756	-0.0555	1.0000	-0.0258	-0.0063	0.0823	0.0657
P. Sistólica	-0.1325	0.0378	-0.0258	1.0000	0.6196	0.3836	0.3825
P. Diastólica	-0.0530	0.2167	-0.0063	0.6196	1.0000	0.0239	-0.0220
Edad	-0.0158	0.0351	0.0823	0.3836	0.0239	1.0000	0.9866
Edad ²	-0.0215	0.0117	0.0657	0.3825	-0.0220	0.9866	1.0000

Finalmente, para garantizar la estabilidad de los futuros modelos, revisamos la matriz de correlación de los predictores (Tabla 2). En general, la mayoría de las correlaciones presentan magnitudes bajas o moderadas, lo que sugiere que no existe una dependencia lineal fuerte entre la mayoría de las variables explicativas ([National Center for Health Statistics, 2024](#)). Destaca la alta correlación positiva entre presión sistólica y presión diastólica (0.6196), lo cual es esperable debido a que ambas corresponden a medidas relacionadas de presión arterial. Asimismo, se observa una correlación moderada entre edad y presión sistólica (0.3836), indicando que, a mayor edad, tienden a aumentar los niveles de presión arterial sistólica.

4. Plan de Modelamiento Estadístico

Como ya se mencionó en la sección anterior, la observación principal en los gráficos es que la dependencia del colesterol a la edad es de forma cuadrática. Como esta relación no necesariamente está centrada en el cero, tampoco lo estará la hipotética parábola, consecuentemente, la relación estará dada necesariamente



por dos covariables: edad y edad². Como el objetivo es comparar con una relación estrictamente lineal, la pregunta de investigación se reduce a medir la importancia de la covariable edad². Considerando esto, se proponen dos modelos anidados con intercepto con las siguientes covariables: $X_1 = \text{RIAGENDIR} - 1$, sexo codificado en 0 para hombres y 1 para mujeres; $X_2 = \text{BMXBMI}$, índice de masa corporal; $X_3 = \text{INDFMPIR}$, razón de ingresos familiares respecto al umbral de pobreza, para medir el nivel socioeconómico del sujeto de la observación; $X_4 = \frac{\text{BPXOSY1} + \text{BPXOSY2} + \text{BPXOSY3}}{3}$, promedio simple de las tres mediciones de la presión sistólica; $X_5 = \frac{\text{BPXODI1} + \text{BPXODI2} + \text{BPXODI3}}{3}$, promedio simple de las tres mediciones de la presión diastólica; $X_6 = \text{RIDAGEYR}$, edad; $X_7 = \text{RIDAGEYR}^2$, edad al cuadrado. Estas covariables nos definen los siguientes modelos:

- Modelo completo Ω : $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \beta_7 X_7 + \varepsilon$
- Modelo reducido ω : $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \varepsilon$

Donde Y es la variable dependiente, en este caso, el colesterol. Con respecto al error ε , asumiremos $\mathbb{E}[\varepsilon|X] = 0$ exogeneidad media para que los estimadores por mínimos cuadrados sean insesgados, por otro lado, debido a que las observaciones son de personas independientes, es seguro asumir $\text{Cov}(\varepsilon|X) = \sigma^2 I_n$ homocedasticidad y no correlación condicional.

Teniendo claramente establecido el modelo, a continuación se comentarán los diagnósticos previstos: en primera instancia se realizarán gráficos para conocer los datos y cómo resultó el ajuste. De los gráficos mencionados los primeros análisis serán las proyecciones de los errores versus cada variable independiente, buscando detectar relaciones no lineales, heterocedasticidad o alguna combinación de estas. Además de los gráficos anteriores se realizará un qqplot.

Anteriormente se mencionó que no se integraron las variables que visualmente tenían relaciones directamente lineales para evitar problemas de colinealidad que deterioren el condicionamiento de la matriz de covariables. Para formalizar este análisis con las variables que sí se integraron al modelo se revisará numéricamente el condicionamiento de la matriz y los VIF por variable.

El test más importante en cuanto a evaluar directamente nuestra pregunta de investigación es comparar modelos anidados incluyendo o no el coeficiente que acompaña al término de edad² (comparación de los modelos Ω y ω descritos anteriormente); además para ambos por separado se va a testear la posibilidad de reducir otras variables bajo criterio de eliminación, revisando valores de CP de Mallows y R_a^2 .

5. Próximos Pasos y Reproducibilidad

En la siguiente etapa del proyecto se procederá con el ajuste empírico de los modelos anidados propuestos (Ω y ω) utilizando la muestra definida, asimismo, se llevarán a cabo las pruebas y diagnósticos explicados en la sección previa.

Para garantizar la reproducibilidad del proyecto, todo el código utilizado para la limpieza de datos, el cruce de los módulos y el Análisis Exploratorio de Datos (EDA) se encuentra disponible en nuestro repositorio público de GitHub: <https://github.com/vgalfaro/EYP230I-Proyecto-NHANES.git>.



Referencias

- Blaak, E. (2001). Gender differences in fat metabolism. Current Opinion in Clinical Nutrition and Metabolic Care, 4(6):499–502.
- Chen, H., Chen, Y., Wu, W., et al. (2021). Total cholesterol, arterial stiffness, and systolic blood pressure: a mediation analysis. Scientific Reports, 11:1330.
- Ferrara, A., Barrett-Connor, E., and Shan, J. (1997). Total, LDL, and HDL cholesterol decrease with age in older men and women. The Rancho Bernardo Study 1984-1994. Circulation, 96(1):37–43.
- National Center for Health Statistics (2024). NHANES. <https://www.cdc.gov/nchs/nhanes/>. Centers for Disease Control and Prevention. Acceso: 21-05-2026.