



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE MATEMÁTICAS
DEPARTAMENTO DE ESTADÍSTICA
PRIMER SEMESTRE 2026

Proyecto NHANES

*Efecto del envejecimiento y factores de riesgo en los niveles de
colesterol*

EYP230I/2307 - Análisis de Regresión

Profesor: Eloy Alvarado **Ayudante:** Matías A. Pineda

Grupo 1

Integrantes:
Vicente Alfaro, Cristian Chávez, Isidora Guíñez, Bruno Parra

Fecha de entrega: 15 de junio de 2026



Índice de contenido

1. Introducción	3
1.1. Pregunta de Investigación	3
1.2. Objetivo	3
2. Datos y Variables de Estudio	3
2.1. Origen de los Datos y Unidad de Observación	3
2.2. Consideraciones Éticas	4
2.3. Descripción de Variables	4
3. EDA	5
3.1. Estadística descriptiva	5
3.2. Tratamiento de los NaN	5
3.3. Codificaciones y Transformaciones	6
3.4. Exploración Visual	7
4. Modelamiento	9
4.1. Especificación de los Modelos	9
5. Diagnóstico y remedios	10
5.1. Linealidad	10
5.2. Análisis residual	11
5.3. Multicolinealidad	12
5.4. Observaciones influyentes	13
5.5. Posibles remedios	13
6. Selección, Validación y Predicción	13
6.1. Capacidad Explicativa de los Modelos	14
6.2. Validación Predictiva e Impacto Clínico	14
6.3. Análisis de Sensibilidad y Robustez del Modelo	15
7. Interpretación y acción propuesta	15
8. Reproducibilidad	17

Índice de Tablas

1. Estadística descriptiva de las variables	5
2. Estadística descriptiva de las variables eliminando colesterol faltantes (NaN)	6
3. Matriz de Correlaciones (Variables Transformadas)	8
4. Comparación de modelos	11
5. Test de Breusch-Pagan	11
6. Número de edades que no rechazan normalidad	11
7. Colinealidad	12
8. Máxima distancia Cook por modelo	13



9.	Cambio Cuadrático en la Predicciones Normalizado por Desviación Estándar	14
10.	Coeficientes modelo completo en ambos sexos Ω	16
11.	coeficientes modelo completo en hombres Ω_h	16
12.	Coeficientes modelo completo en mujeres Ω_m	16

Índice de figuras

1.	Distribución del colesterol Total	7
2.	Gráficos de Colesterol vs Edad	8
3.	Gráficos de Residuos vs Ajustados para el modelo global (Ω y ω)	10
4.	Comparación de gráficos Q-Q para los modelos segregados	12



1. Introducción

Según Centers for Disease Control and Prevention (Centers for Disease Control and Prevention, 2024), la concentración de colesterol en sangre constituye un indicador relevante para evaluar la salud cardiovascular, ya que niveles elevados pueden favorecer la acumulación de placas en las arterias y aumentar el riesgo de enfermedades cardiovasculares. Sin embargo, el comportamiento del colesterol a lo largo de la vida no necesariamente sigue un patrón constante ni estrictamente lineal. Diversos estudios han mostrado que, aunque los niveles de colesterol tienden a aumentar con la edad durante la adultez, en edades más avanzadas pueden observarse fenómenos de estabilización o incluso disminución (Manolio et al., 2004). En este contexto, el presente trabajo busca estudiar la relación entre edad y colesterol. En particular, se analiza si los niveles de colesterol en sangre aumentan de forma constante o, por el contrario, presentan algún grado de estabilización o decaimiento en edades avanzadas. El objetivo final es construir un modelo estadístico que permita evaluar esta relación a partir de los datos observados.

1.1. Pregunta de Investigación

¿Es la relación entre la edad y colesterol total estrictamente lineal o existe una caída/estabilización en edades avanzadas, ajustando por sexo, IMC y presión arterial?

1.2. Objetivo

El presente estudio adopta un enfoque principalmente descriptivo y explicativo. El análisis se orienta a caracterizar las observaciones y/o asociaciones entre variables. En consecuencia, se prioriza la comprensión de la estructura de las relaciones por sobre la elaboración de herramientas de predicción y/o inferencia exacta. Los resultados se interpretan en términos de asociación y no como evidencia de relaciones causales.

2. Datos y Variables de Estudio

2.1. Origen de los Datos y Unidad de Observación

Los datos utilizados en este estudio provienen de la *National Health and Nutrition Examination Survey* (NHANES), un programa de estudios diseñado para evaluar el estado de salud y nutrición de adultos y niños en los Estados Unidos. En particular, se utiliza el ciclo de datos del período 2021-2023. La unidad de observación corresponde a un individuo examinado dentro de la encuesta (National Center for Health Statistics, 2024). La base de datos original se distribuye en múltiples módulos independientes en formato SAS Transport (.xpt). Para la consolidación de la muestra analítica, se cruzaron los registros de cuatro módulos clave utilizando el identificador único de cada paciente (SEQN): Demografía (DEMO_L), Medidas Corporales (BMX_L), Presión Arterial (BPXO_L) y Colesterol Total (TCHOL_L). La base de datos cruda resultante consta de un total de $N = 7801$ y 8 variables de estudio.



2.2. Consideraciones Éticas

El uso de esta base de datos se enmarca en un contexto estrictamente académico y estadístico. Los datos de NHANES son de dominio público y han sido previamente anonimizados por el *National Center for Health Statistics* (NCHS) del CDC, garantizando que no sea posible identificar a los individuos encuestados. El análisis propuesto no busca la estigmatización de ningún subgrupo demográfico, sino comprender las relaciones entre las medidas externas del cuerpo e indicadores cardiovasculares.

2.3. Descripción de Variables

■ Variable dependiente

- **Colesterol Total (LBXTC):** Variable numérica continua medida en (mg/dL) que representa la concentración de colesterol total en sangre.

■ Variable de interés

- **Edad (RIDAGEYR):** Variable numérica que indica la edad del participante en años al momento de la realización del examen.

■ Variables de control

- **Sexo (RIAGENDR):** Variable categórica codificada (0 = Masculino, 1 = Femenino). Se incorpora como variable de control debido a las diferencias biológicas y hormonales existentes en el metabolismo de las grasas entre hombres y mujeres (Blaak, 2001).
- **Índice de Masa Corporal (BMXBMI):** Variable numérica continua medida en (kg/m^2), calculada a partir del peso y la altura del individuo. El IMC se utiliza como indicador del estado nutricional y metabólico, factores que pueden influir directamente en los niveles de colesterol de una persona.
- **Presión Arterial Sistólica (Pres_sis):** Variable numérica continua medida en mmHg, correspondiente a la media de las 3 mediciones disponibles (BPX0SY1, BPX0SY2, BPX0SY3) de la presión sistólica (fase de contracción del corazón). La literatura sugiere que la presión sistólica y el colesterol están positivamente relacionados (Chen et al., 2021).
- **Presión Arterial Diastólica (Pre_dia):** Variable numérica continua medida en mmHg, correspondiente a la media de las 3 mediciones disponibles (BPXODI1, BPXODI2, BPXODI3) de la presión diastólica (fase de relajación del corazón). Se agrega la presión diastólica para controlar la salud cardiovascular general. En este estudio, esta variable actúa como insumo intermedio, ya que será transformada para evitar problemas de colinealidad con la presión sistólica.
- **Rango de Presión Arterial (Rpres):** Variable numérica continua (mmHg) construida a partir de la diferencia matemática entre la Presión Sistólica y la Presión Diastólica estimadas. Esta transformación permite integrar la información completa del paciente sobre la presión en el modelo final mitigando la inflación de varianza (VIF).



3. EDA

En esta sección se realiza un análisis exploratorio de los datos con el objetivo de comprender las principales características de las variables consideradas en el estudio, identificar patrones y detectar relaciones relevantes entre ellas. En particular, se analiza la presencia de valores faltantes, las codificaciones utilizadas y el comportamiento de las variables mediante gráficos y estadística. Este análisis permite evaluar la calidad de los datos y orientar la construcción del modelo de regresión.

3.1. Estadística descriptiva

Tabla 1

Estadística descriptiva de las variables

Variable	Mín.	Q1	Mediana	Media	Q3	Máx.	NA's
Colesterol Total (mg/dL)	62.0	151.0	178.0	182.1	208.0	438.0	1036
Edad (años)	8.0	23.0	47.0	44.83	65.0	80.0	0
Sexo	1.0	1.0	2.0	1.539	2.0	2.0	0
IMC (kg/m ²)	11.10	23.00	27.20	28.31	32.40	74.80	110
Presión Sistólica (mmHg)	71.33	106.33	116.33	119.10	129.00	232.33	323
Presión Diastólica (mmHg)	34.00	64.00	71.67	72.22	79.33	139.00	323

La Tabla 1 presenta un resumen descriptivo de las variables consideradas en el análisis. Se observa que la edad de los participantes varía entre 8 y 80 años, con una mediana de 47 años. El colesterol total presenta una media de 182.1 mg/dL y una mediana de 178 mg/dL, lo que sugiere una distribución relativamente centrada, aunque con algunos valores elevados. Asimismo, se aprecia una cantidad importante de datos faltantes en la variable colesterol total (1036 observaciones), mientras que las variables de presión arterial e IMC presentan una proporción considerablemente menor de valores ausentes.

3.2. Tratamiento de los NaN

Durante la etapa de preprocesamiento se identificaron valores faltantes (*NaN*) en distintas variables del conjunto de datos. En el caso de la variable dependiente, correspondiente al colesterol total, se optó por eliminar observaciones con valores faltantes. Esta decisión se tomó debido a la considerable proporción de estos casos, por lo que rellenar tales datos faltantes asumiría relaciones a la variable dependiente, introduciendo relaciones artificiales al objeto de estudio. Después de eliminar las observaciones correspondientes quedaron $N = 6765$ observacion. Además, se observaron mínimos cambios a las estadísticas descriptivas de la base de datos.



Tabla 2

Estadística descriptiva de las variables eliminando colesterol faltantes (NaN)

Variable	Mín.	Q1	Mediana	Media	Q3	Máx.	NA's
Colesterol Total (mg/dL)	62.0	151.0	178.0	182.1	208.0	438.0	0
Edad (años)	8.0	27.0	49.0	46.44	65.0	80.0	0
Sexo	1.0	1.0	2.0	1.539	2.0	2.0	0
IMC (kg/m ²)	12.90	23.50	27.40	28.60	32.60	74.80	82
Presión Sistólica (mmHg)	74.67	107.00	117.00	119.57	129.00	232.33	237
Presión Diastólica (mmHg)	34.00	64.67	72.00	72.60	79.33	139.00	237

Para las variables de control que presentaban valores faltantes, particularmente las mediciones de presión arterial, se aplicó una estrategia de imputación basada en grupos homogéneos de edad y sexo. Específicamente, cuando una observación presentaba un valor faltante en alguna medición de presión arterial, este fue reemplazado por el promedio calculado a partir de todos los individuos del mismo sexo y edad. Por ejemplo, si un hombre de 20 años tenía una medición de presión arterial faltante, esta se reemplazó por el promedio de dicha medición entre todos los hombres de 20 años presentes en la muestra. La elección de esta metodología se fundamenta en que variables fisiológicas como la presión arterial presentan una fuerte dependencia tanto de la edad como del sexo. Diversos estudios han mostrado que la presión arterial tiende a aumentar con la edad y que existen diferencias sistemáticas entre hombres y mujeres. (Ferrara et al., 1997) Por lo tanto, imputar utilizando promedios calculados dentro de grupos demográficamente similares permite preservar mejor la estructura de los datos que una imputación mediante un promedio global.

3.3. Codificaciones y Transformaciones

- **Sexo (RIAGENDR):** Se utilizó una codificación binaria mediante una variable indicadora, asignando el valor 0 a los participantes de sexo masculino y el valor 1 a los participantes de sexo femenino.
- **Edad (RIDAGEYR):** Se procedió a centrar esta variable respecto a su media muestral ($\text{Edad}_{\text{centrada}} = \text{Edad} - \overline{\text{Edad}}$). Esto para evitar la multicolinealidad estructural al incluir el término cuadrático (Edad^2) en el modelo. De esta forma, se garantiza un correcto condicionamiento de la matriz de diseño para evaluar empíricamente la hipótesis de curvatura.
- **Rango de Presión Arterial (Rpres):** Dado que las presiones sistólica y diastólica presentan una alta correlación natural, se calculó el rango de presión (presión de pulso) como la diferencia entre ambas métricas (Presión Sistólica – Presión Diastólica). Esta transformación permite incluir la información completa en el modelo reduciendo el riesgo de inflación de varianza (VIF) entre los predictores de presión.
- **Estimador Óptimo para las Presiones Arteriales (BLUE):** Para reducir la dimensionalidad y el error de medición, se utilizó la media aritmética de las 3 mediciones disponibles por paciente para estimar tanto la presión sistólica como la diastólica.



Llamando Z_1 , Z_2 y Z_3 a estas 3 mediciones, se puede argumentar que son independientes, ya que en el protocolo de NHANES el paciente es sometido a 5 minutos de reposo previo y se deja un lapso de un minuto entre cada medición. Si asumimos equipos calibrados y mediciones hechas por personal entrenado, estas serán insesgadas, se tiene que $\mathbb{E}[Z] = \mu$ y $\text{var}(Z) = \sigma^2$.

Definiendo un estimador lineal general $\hat{Z} = c_1 Z_1 + c_2 Z_2 + c_3 Z_3$, para que este sea insesgado se requiere que $c_1 + c_2 + c_3 = 1$. Su varianza estará dada por:


$$\begin{aligned}\text{var}(\hat{Z}) &= \text{var}(c_1 Z_1 + c_2 Z_2 + c_3 Z_3) \\ &= \text{var}(c_1 Z_1) + \text{var}(c_2 Z_2) + \text{var}(c_3 Z_3) \\ &= (c_1^2 + c_2^2 + c_3^2) \sigma^2\end{aligned}$$

Esta expresión cuadrática se minimiza bajo la restricción de insesgamiento cuando $c_1 = c_2 = c_3 = \frac{1}{3}$. Por lo tanto, por el Teorema de Gauss-Markov, el promedio aritmético es el Mejor Estimador Lineal Insesgado (BLUE) para la presión arterial de cada paciente, justificando su uso como variable de entrada.

3.4. Exploración Visual

Imagen 1


Distribución del colesterol Total




La imagen 1 muestra la distribución marginal del colesterol total en la muestra analizada. Se observa una distribución unimodal, con una mayor concentración de observaciones entre los 150 y 220 mg/dL aproximadamente. El valor más frecuente se encuentra cercano a los 180 mg/dL. Además, la distribución presenta una ligera asimetría positiva, evidenciando una cola más extensa hacia valores altos de colesterol. Esto nos indica la presencia de algunos individuos con niveles considerablemente elevados de colesterol, alcanzando valores superiores a 300 mg/dL. Sin embargo, estos casos son poco frecuentes en comparación con la concentración principal de los datos.

Imagen 2

Gráficos de Colesterol vs Edad



(a) Colesterol Total vs Edad



(b) Colesterol Total vs Edad por Sexo

Al graficar las dos variables de interés (2a), es posible apreciar cómo la regresión local (línea roja) tiene una forma cóncava lo cual asimilaría a una relación cuadrática entre ambos. Al distinguir por sexo (Imagen 3) observamos cómo existe una diferencia en la tendencia de colesterol total. En hombres el colesterol alcanza su máximo alrededor de 45 años para luego ir a la baja, en contraste, las mujeres presentan una curva más estable que alcanza su máximo esperado en los 60 años. Esta divergencia confirma que el sexo es una variable de control fundamental a considerar en la especificación del modelo.

Tabla 3

Matriz de Correlaciones (Variables Transformadas)

	Sexo	IMC	P. Sistólica	P. Diastólica	Edad	Edad ²	Rango Pres.
Sexo	1.0000	0.0683	-0.1216	-0.0316	0.0094	-0.0487	-0.1362
IMC	0.0683	1.0000	0.1498	0.3127	0.2438	-0.3183	-0.0640
P. Sistólica	-0.1216	0.1498	1.0000	0.6663	0.5082	-0.1332	0.7756
P. Diastólica	-0.0316	0.3127	0.6663	1.0000	0.2715	-0.4280	0.0460
Edad	0.0094	0.2438	0.5082	0.2715	1.0000	-0.2401	0.4509
Edad ²	-0.0487	-0.3183	-0.1332	-0.4280	-0.2401	1.0000	0.1839
Rango Pres.	-0.1362	-0.0640	0.7756	0.0460	0.4509	0.1839	1.0000

Finalmente, para evaluar la estabilidad numérica de los modelos de regresión propuestos, analizamos la matriz de correlación empírica de los predictores (Tabla 2). En términos generales, se observan magnitudes bajas a moderadas, lo que sugiere la ausencia de dependencias lineales severas entre la mayoría de las covariables. Destaca la alta correlación positiva entre la presión sistólica y diastólica (0.6196), lo cual es esperable por su estrecha relación fisiológica. Asimismo, se registra una correlación moderada (0.3836) entre la edad y la presión sistólica, indicando la tendencia natural al aumento de la presión arterial durante el envejecimiento.



4. Modelamiento

A partir de la evidencia obtenida en el Análisis Exploratorio de Datos, la relación entre el colesterol total y la edad sugiere un comportamiento cuadrático. Adicionalmente, al desagregar por sexo, se observan diferencias en las trayectorias de envejecimiento, lo que motiva la necesidad de evaluar el efecto de la edad tanto a nivel poblacional global como en submuestras estratificadas.

Para formalizar esta hipótesis y evitar los problemas de multicolinealidad estructural advertidos previamente, se define el siguiente vector de covariables para los modelos, considerando la edad centrada respecto a la media de la muestra y el rango de presión (**Rpres**) en lugar de las presiones crudas aisladas:

- $X_1 = \text{Sexo}$ (Variable indicadora: 0 = Hombre, 1 = Mujer)
- $X_2 = \text{IMC (BMXBMI)}$
- $X_3 = \text{Presión Diastólica (Pres_dia)}$
- $X_4 = \text{Rango de Presión (Rpres)}$
- $X_5 = \text{Edad}_{\text{centrada}} = (\text{Edad} - \overline{\text{Edad}})$
- $X_6 = \text{Edad}_{\text{centrada}}^2$

4.1. Especificación de los Modelos

Para concluir la pregunta de investigación empíricamente, se ajustarán tres pares de modelos anidados (un modelo completo con la curvatura y un modelo reducido estrictamente lineal).

1. Modelos Globales (Población Total): Evalúan la presencia de la curvatura controlando por el efecto fijo del sexo.

$$\text{Completo } (\Omega) : Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \varepsilon$$

$$\text{Reducido } (\omega) : Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \varepsilon$$

2. Modelos Estratificados para Hombres ($X_1 = 0$):

$$\text{Completo } (\Omega_H) : Y = \alpha_0 + \alpha_2 X_2 + \alpha_3 X_3 + \alpha_4 X_4 + \alpha_5 X_5 + \alpha_6 X_6 + \varepsilon$$

$$\text{Reducido } (\omega_H) : Y = \alpha_0 + \alpha_2 X_2 + \alpha_3 X_3 + \alpha_4 X_4 + \alpha_5 X_5 + \varepsilon$$

3. Modelos Estratificados para Mujeres ($X_1 = 1$):

$$\text{Completo } (\Omega_M) : Y = \gamma_0 + \gamma_2 X_2 + \gamma_3 X_3 + \gamma_4 X_4 + \gamma_5 X_5 + \gamma_6 X_6 + \varepsilon$$

$$\text{Reducido } (\omega_M) : Y = \gamma_0 + \gamma_2 X_2 + \gamma_3 X_3 + \gamma_4 X_4 + \gamma_5 X_5 + \varepsilon$$

5. Diagnóstico y remedios


5.1. Linealidad

El supuesto de linealidad asume que la esperanza condicional de la variable respuesta está correctamente especificada por la combinación lineal de los regresores. Para evaluarlo, se analizaron empíricamente los gráficos de Residuos versus Valores Ajustados ($\hat{Y}$) tanto para el modelo reducido como para el modelo completo.


Como se observa en los diagnósticos visuales, dada la inmensa varianza biológica inherente a los niveles de colesterol en la población general, la inspección gráfica resulta inconclusa. La LOESS (línea roja) en el modelo reducido apenas insinúa una leve desviación, la cual se aplanan marginalmente al transicionar al modelo cuadrático completo.

Imagen 3

Gráficos de Residuos vs Ajustados para el modelo global (Ω y ω)



(a) Residuos vs Ajustados Ω



(b) Residuos vs Ajustados ω

Dado que esta prueba no es concluyente, se sometió a prueba la pertinencia del decaimiento cuadrático en la vejez mediante un Test F Parcial. La hipótesis nula del contraste asume que la trayectoria del colesterol es estrictamente lineal, lo que equivale a restringir el coeficiente del término cuadrático a cero ($\mathcal{H}_0 : \beta_6 = 0$ para el modelo global, $\alpha_6 = 0$ en hombres y $\gamma_6 = 0$ en mujeres).

Como se reporta en la Tabla 4, al contrastar las sumas de cuadrados de los residuos del modelo reducido (ω) frente al modelo completo (Ω), se obtiene un estadístico F asociado a un valor $p < 2 \times 10^{-16}$ en los tres escenarios evaluados (población total, submuestra masculina y submuestra femenina).

Dada esta contundente evidencia estadística, se rechaza categóricamente la hipótesis nula con cualquier nivel de significancia convencional ($\alpha = 0.05, 0.01$). Esto permite concluir de manera empírica que la inclusión de la variabilidad cuadrática (Edad^2) no es injustificado, sino que aporta una mejora estructural sistemática en la capacidad explicativa del modelo. En consecuencia, el modelo lineal simple queda descartado a favor de la especificación cuadrática.



Tabla 4

Comparación de modelos

Modelo	R^2	R^2 Ajustado	p -value
Ambos Sexos Completo Ω	0.153	0.1523	$< 2 \times 10^{-16}$
Ambos Sexos Reducido ω	0.1181	0.1174	$< 2 \times 10^{-16}$
Hombres Completo Ω_h	0.1505	0.1492	$< 2 \times 10^{-16}$
Hombre Reducido ω_h	0.1038	0.1027	$< 2 \times 10^{-16}$
Mujeres Completo Ω_m	0.1627	0.1615	$< 2 \times 10^{-16}$
Mujeres Reducido ω_m	0.1375	0.1366	$< 2 \times 10^{-16}$

5.2. Análisis residual

Los resultados del test de Breusch-Pagan presentes en la Tabla 5 muestran que existe evidencia significativa de heterocedasticidad a lo largo de todos los modelos. Tanto para la muestra conjunta como para los modelos estratificados por sexo, en sus versiones completa y reducida, los p -values son considerablemente inferiores a un nivel de significancia estándar, por ejemplo un 5 %. Consecuentemente, se rechazó la hipótesis de homocedasticidad.

Tabla 5

Test de Breusch-Pagan

Modelo	p -values
Ambos Sexos Completo Ω	5.12×10^{-22}
Ambos Sexos Reducido ω	4.84×10^{-20}
Hombres Completo Ω_h	1.29×10^{-11}
Hombre Reducido ω_h	2.8×10^{-9}
Mujeres Completo Ω_m	6.9×10^{-13}
Mujeres Reducido ω_m	9.24×10^{-14}

Dado que la edad es la principal variable de interés en cada modelo, se considero estudiar como se comportan los residuos condicionados a la edad. Para ello, se evaluó la distribución por edad mediante el test de normalidad Shapiro-Wilk con una significancia del 5 %, cuyos resultados se encuentran en la tabla 6

Tabla 6

Número de edades que no rechazan normalidad

Modelo	Cantidad
Ambos Sexos Completo Ω	1
Ambos Sexos Reducido ω	1
Hombres Completo Ω_h	59
Hombre Reducido ω_h	58
Mujeres Completo Ω_m	0
Mujeres Reducido ω_m	0


Los resultados muestran diferencias importantes según el sexo. En los modelos que consideran ambos, la normalidad se rechaza en todas las edades excepto en una. Para las mujeres, la normalidad es rechazada




en casi todas las edades. En contraste, para los hombres es lo opuesto, en todas las edades de la muestra con una significancia del 5 % no se rechaza normalidad en los residuos.

Imagen 4

Comparación de gráficos $Q-Q$ para los modelos segregados



(a) $Q-Q$ -residuals Modelo Completo Hombres Ω_h



(b) $Q-Q$ -residuals Modelo Completo Mujeres Ω_m

Para evidenciar de manera gráfica estos resultados, se utilizaron gráficos $Q-Q$ -residuals presentes en las imagenes 4a y 4b. En el modelo de mujeres se observa una cola más extensa y una mayor separación de la linea, lo que evidencia mayor lejanía a la normalidad, mientras que los hombres presentan mejor ajuste visual

5.3. Multicolinealidad

Para cada modelo de regresión se calcularon los VIF para cada covariable, los resultados se presentan en la tabla 7.

Tabla 7

Colinealidad

Modelo	Sexo	IMC	Presión Diastólica	Rango de Presión	Edad	Edad ²
Ambos Sexos Completo Ω	1.031	1.212	1.324	1.473	1.547	1.432
Ambos Sexos Reducido ω	1.031	1.187	1.167	1.340	1.454	-
Hombres Completo Ω_h	-	1.240	1.380	1.265	1.412	1.452
Hombre Reducido ω_h	-	1.212	1.161	1.208	1.353	-
Mujeres Completo Ω_m	-	1.187	1.283	1.662	1.721	1.434
Mujeres Reducido ω_m	-	1.164	1.175	1.435	1.578	-

Gracias al previo centrado de la edad y el uso del rango de pulso en vez de presión sistólica, todos los valores VIF son menores a 2. Con esto en consideración se descarta la presencia de multicolinealidad severa, validando así, que las matrices de covariables en cada modelo son numéricamente estables.



5.4. Observaciones influyentes

Con respecto a observaciones importantes y/o influyentes para los ajustes de los modelos. En primera instancia, observando la imagen 2a es posible plantear que debido a la gran cantidad de observaciones, no se presencian una cantidad suficiente de *outliers* que puedan afectar mucho las regresiones.

Para formalizar esta idea, se calculo la distancia de Cook para cada muestra en cada modelo, cuyos resultados están presentes en la tabla 8. Como ninguna muestra presento una distancia mayor que 1, se concluye que no existe influencias significativas en observaciones particulares.

Tabla 8

Máxima distancia Cook por modelo

Modelo	Máxima distancia Cook
Ambos Sexos Completo Ω	8.38×10^{-3}
Ambos Sexos Reducido ω	9.61×10^{-3}
Hombres Completo Ω_h	1.2×10^{-2}
Hombre Reducido ω_h	1.4×10^{-2}
Mujeres Completo Ω_m	1.6×10^{-2}
Mujeres Reducido ω_m	1.9×10^{-2}

5.5. Posibles remedios

Para el análisis de residual antes se vio que estos no cumplen con el supuesto de homocedasticidad, lo que se puede deber a que por el diseño metodológico de muestreo de NHANES, hay una sobrerrepresentación de ciertos grupos demográficos, lo que se puede corregir implementando un modelo de WLS (Weighted Least Squares) con los pesos dados por la organización, en este caso para el periodo de 2023 (National Center for Health Statistics, a).

En cuanto a las observaciones influyentes, en la documentación provista por NHANES se recomienda el uso de transformaciones en la variable dependiente dentro de los siguientes tipos comunes: LOGIT, LOG, LOG10, SQRT, INVERSE o ARCSIN (National Center for Health Statistics, b).

Por último, debido a que no existe evidencia clara de que haya normalidad en los residuos de los modelos, las inferencias hechas no son exactas. No obstante, dado el elevado tamaño de la muestra, es razonable recurrir a las propiedades asintóticas de los estimadores y al teorema central del límite para justificar que las inferencias pueden considerarse razonablemente válidas de manera aproximada.

6. Selección, Validación y Predicción

Con los resultados de los test de hipótesis de la sección anterior, en la cual se dejó entrever que un modelo con término cuadrático en la edad es superior, procedemos a cuantificar la mejora de los modelos.



6.1. Capacidad Explicativa de los Modelos

Para evaluar la ganancia en la explicabilidad de un modelo lineal (modelos reducidos ω) hacia uno con término cuadrático (modelos completos Ω), podemos observar cambios en los términos R^2 y R_a^2 .

Al incorporar el término de la edad centrada al cuadrado (X_7), se observa una mejora sistemática y generalizada en el poder explicativo del modelo en todas las poblaciones estudiadas (ver Tabla 4:

- **Modelo Global:** El R_a^2 aumenta de un 11.74 % a un 15.23 %, logrando una mejora absoluta de 3.49 % en la varianza explicada del colesterol total.
- **Submuestra Masculina:** Es donde se registra el impacto más severo de la curvatura. El R_a^2 sube de un 10.27 % a un 14.92 %, lo que representa una mejora analítica de 4.65 % absoluto. Esto demuestra que omitir la tasa de decaimiento penaliza fuertemente la calidad del ajuste en hombres.
- **Submuestra Femenina:** El paso al modelo completo genera un incremento de 2.82 % absoluto en el R_a^2 (alcanzando un 16.15 %). Esto es coherente con la exploración visual previa, donde la trayectoria de las mujeres presentaba un máximo más tardío y una curva menos pronunciada.

El hecho de que el R_a^2 aumente de forma consistente confirma que la reducción en la Suma de Cuadrados de los Residuos (SCR) compensa con creces la pérdida del grado de libertad matemático al penalizar por el nuevo parámetro.

6.2. Validación Predictiva e Impacto Clínico

Dado que el enfoque principal de este estudio es descriptivo-explicativo, la evaluación predictiva se centró en medir cómo la selección del modelo altera los valores esperados a nivel individual. Para ello, se calculó el cambio cuadrático medio en las predicciones de ambos modelos, normalizado por la desviación estándar del colesterol total (Tabla 9).

Tabla 9

Cambio Cuadrático en la Predicciones Normalizado por Desviación Estándar

Modelo	Variación
Ambos Sexos	18.7 %
Hombres	21.6 %
Mujeres	15.9 %

Los resultados evidencian que la elección de un modelo cuadrático tiene una alta significancia práctica. En el modelo global, cambiar de una recta a una parábola altera las predicciones de los pacientes en un 18.7 % de una desviación estándar. Este impacto se agudiza en la submuestra de hombres (21.6 %) y se modera en las mujeres (15.9 %). Por lo tanto, validar el modelo completo evita un sesgo sistemático de predicción que subestimaría drásticamente el colesterol en la mediana edad y lo sobrestimaría de forma errónea en la vejez avanzada.



6.3. Análisis de Sensibilidad y Robustez del Modelo

Para garantizar que la curvatura seleccionada no es provocada por un grupo reducido de datos extremos, se procedió a realizar un análisis de sensibilidad. Se evaluó la potencial presencia de observaciones con alta influencia estructural mediante el cálculo de la Distancia de Cook para todos los pacientes incluidos en los modelos completos (Ω).

Como se mostró en la sección pasada, los diagnósticos indicaron que el valor máximo de la Distancia de Cook para cualquier individuo de la muestra fue estrictamente menor a 1. Este hallazgo descarta la existencia de puntos de apalancamiento severo. Por consiguiente, se determinó que la inclusión de los pacientes con valores de colesterol más altos (valores por sobre los 300 mg/dL) es estadísticamente segura y no distorsiona los estimadores β por Mínimos Cuadrados Ordinarios.

La decisión metodológica final fue conservar la muestra íntegra, concluyendo que la persistencia de la concavidad negativa en la vejez presenta robustez estructural y muestra una tendencia poblacional real y no el reflejo de anomalías o valores atípicos aislados.

7. Interpretación y acción propuesta

El objetivo principal de este estudio fue evaluar la relación entre la edad y los niveles de colesterol total, determinando si dicha relación puede describirse adecuadamente mediante un modelo lineal. En esta sección se interpretan los resultados del modelo seleccionado, enfatizando la forma de la relación estimada entre edad y colesterol, así como el efecto de las demás variables incluidas en el análisis. Finalmente, se discuten las implicancias de estos resultados y las limitaciones del estudio.

Como se observa en las Tablas 10, 11 y 12, el coeficiente asociado al término cuadrático de la edad ($Edad^2$) es negativo y estadísticamente significativo en los tres modelos considerados ($p < 0.001$ en todos los casos). En particular, los coeficientes estimados fueron -0.0227 para la muestra completa, -0.0259 para los hombres y -0.0194 para las mujeres. Estos resultados sugieren que, aunque los niveles de colesterol tienden a aumentar durante gran parte de la adultez, dicho incremento se desacelera progresivamente a medida que avanza la edad, alcanzando eventualmente una etapa de estabilización e incluso una disminución en edades más avanzadas.



Tabla 10

Coefficientes modelo completo en ambos sexos Ω

Variable	Estimado	Error Estandar	<i>t-value</i>	$\mathbb{P}(> t)$
Intercepto	164.009657	4.547785	36.064	$< 2 \times 10^{-16}$
Sexo	9.722761	0.965846	10.067	$< 2 \times 10^{-16}$
IMC	-0.524875	0.069621	-7.539	5.35×10^{-14}
Presión Diastólica	0.626701	0.048802	12.842	$< 2 \times 10^{-16}$
Rango de Presión	-0.140468	0.043576	-3.224	1.27×10^{-3}
Edad	0.287615	0.026796	10.734	$< 2 \times 10^{-16}$
Edad ²	-0.022734	0.001361	-16.703	$< 2 \times 10^{-16}$

Tabla 11

coeficientes modelo completo en hombres Ω_h

Variable	Estimado	Error Estandar	<i>t-value</i>	$\mathbb{P}(> t)$
Intercepto	162.93953	6.87517	23.700	$< 2 \times 10^{-16}$
IMC	-0.42015	0.11312	-3.714	2.07×10^{-4}
Presión Diastólica	0.70586	0.07130	9.900	$< 2 \times 10^{-16}$
Rango de Presión	-0.26497	0.06523	-4.062	4.99×10^{-5}
Edad	0.04967	0.03665	1.355	0.175389
Edad ²	-0.02591	0.00198	-13.085	$< 2 \times 10^{-16}$

Tabla 12

Coefficientes modelo completo en mujeres Ω_m

Variable	Estimado	Error Estandar	<i>t-value</i>	$\mathbb{P}(> t)$
Intercepto	183.206280	5.857587	31.277	$< 2 \times 10^{-16}$
IMC	-0.578200	0.087014	-6.645	3.49×10^{-11}
Presión Diastólica	0.514796	0.066037	7.796	8.31×10^{-15}
Rango de Presión	-0.171985	0.058882	-2.921	0.00351
Edad	0.543847	0.038796	14.018	$< 2 \times 10^{-16}$
Edad ²	-0.019428	0.001858	-10.457	$< 2 \times 10^{-16}$

Asimismo, se observan diferencias relevantes entre hombres y mujeres. De acuerdo con la Tabla 11, en el modelo masculino el término lineal de la edad no resulta estadísticamente significativo ($p = 0.175$), mientras que el término cuadrático mantiene una magnitud negativa considerable ($\alpha_6 = -0.0259$). En contraste, la Tabla 12 muestra que en el modelo femenino el coeficiente lineal de la edad es positivo y altamente significativo ($\gamma_6 = 0.544$, $p < 0.001$), acompañado de un término cuadrático negativo de menor magnitud ($\beta = -0.0194$). En conjunto, estos resultados sugieren que el colesterol aumenta de manera más sostenida en las mujeres, mientras que la desaceleración y posterior disminución ocurren a edades más tempranas en los hombres.



Respecto de las demás variables explicativas, los resultados de las Tablas 10, 11 y 12 indican que la presión arterial diastólica presenta una asociación positiva y estadísticamente significativa con los niveles de colesterol total en todos los modelos analizados. Por otra parte, el índice de masa corporal (IMC) exhibe una asociación negativa una vez controlado el efecto de las demás covariables incluidas en el modelo. De forma similar, el rango de presión arterial también aparece asociado negativamente con los niveles de colesterol.

A partir de los coeficientes estimados para los términos de $Edad$ y $Edad^2$, es posible determinar la edad en la que el modelo predice un nivel máximo de colesterol y, por lo tanto, un mayor riesgo de enfermedades cardiovasculares. Dado un modelo, para estimar esta edad de máximo colesterol se deriva con respecto a la edad y se iguala a cero, obteniendo que ocurre en la edad crítica de $Edad^* = \frac{-\epsilon_{Edad}}{2 \cdot \epsilon_{Edad^2}}$.

Utilizando la fórmula anterior para los modelos completos estratificados entre hombres y mujeres (ver tablas 11 y 12 para ver los coeficientes), se obtienen aproximadamente 1 y 14 años respectivamente, pero como se estaba trabajando con una edad centrada al rededor de la media global de aproximadamente 45 años, finalmente vemos que las edades críticas son 46 años para hombres y 59 años para mujeres. Dadas estas diferencias intersexo se le recomienda a las autoridades de salud la realización de campañas de prevención y monitoreo enfocadas en distintos sectores etarios para hombres y mujeres.

Finalmente, los resultados deben interpretarse considerando ciertas limitaciones. El modelo no incorpora diversas variables que podrían afectar los niveles de colesterol en sangre de una persona. Entre ellas se encuentra el uso de medicamentos destinados al control de lípidos u otras condiciones médicas, factores genéticos y antecedentes familiares, hábitos alimenticios, nivel de actividad física y otros factores relacionados al estilo de vida. La ausencia de estas variables podría limitar la capacidad explicativa del modelo, por lo que los resultados deben interpretarse en el contexto de las variables efectivamente observadas y analizadas en este estudio.

8. Reproducibilidad

Para garantizar la reproducibilidad y transparencia de los resultados presentados en este informe, todo el código utilizado para el procesamiento de datos, análisis estadístico y generación de figuras se encuentra disponible en nuestro repositorio público de GitHub: <https://github.com/vgalfaro/EYP230I-Proyecto-NHANES.git>.



Referencias

- Blaak, E. (2001). Gender differences in fat metabolism. Current Opinion in Clinical Nutrition and Metabolic Care, 4(6):499–502.
- Centers for Disease Control and Prevention (2024). About cholesterol. Accessed: 2026-06-12.
- Chen, H., Chen, Y., Wu, W., et al. (2021). Total cholesterol, arterial stiffness, and systolic blood pressure: a mediation analysis. Scientific Reports, 11:1330.
- Ferrara, A., Barrett-Connor, E., and Shan, J. (1997). Total, LDL, and HDL cholesterol decrease with age in older men and women. The Rancho Bernardo Study 1984-1994. Circulation, 96(1):37–43.
- Manolio, T. A., Cushman, M., Gottdiener, J. S., Dobs, A., Kuller, L. H., Kronmal, R. A., and Group, C. C. R. (2004). Predictors of falling cholesterol levels in older adults: the cardiovascular health study. Annals of Epidemiology, 14(5):325–331.
- National Center for Health Statistics. National health and nutrition examination survey (NHANES) - sources and definitions. <https://www.cdc.gov/nchs/hus/sources-definitions/nhanes.htm>. Accedido: 14 de junio de 2026.
- National Center for Health Statistics. NHANES tutorials - datasets and documentation module. <https://wwwn.cdc.gov/nchs/nhanes/tutorials/datasets.aspx>. Accedido: 14 de junio de 2026.
- National Center for Health Statistics (2024). NHANES. <https://www.cdc.gov/nchs/nhanes/>. Centers for Disease Control and Prevention. Acceso: 21-05-2026.